

Analiza semnalelor radar în prezență ecourilor marine

Abordare CFAR-STFT cu adaptări pentru date reale

Ingrid Corobana Teodora Nae

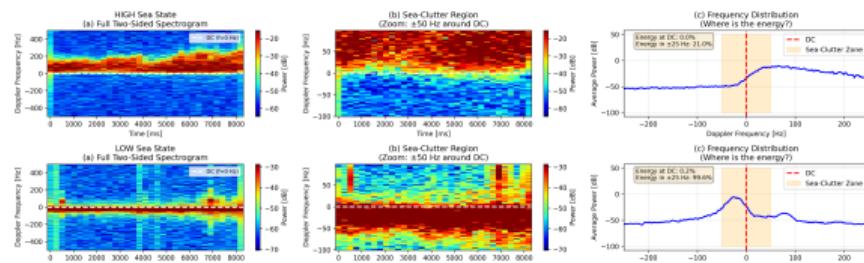
Universitatea din București
Facultatea de Matematică și Informatică
Coordonator: Prof. Dr. Cristian Rusu

Procesarea Semnalelor – 2026

Problema și Soluția CFAR-STFT

Sea Clutter:

- Ecouri radar de la suprafața mării
- Non-Gaussian (spike-uri frecvente)
- Ascunde target-uri mici

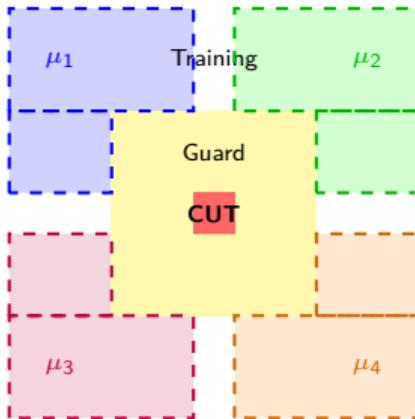


Pipeline CFAR-STFT:

- ① STFT → spectrogramă
- ② CFAR 2D → detecție adaptivă
- ③ DBSCAN → clustering
- ④ Dilatare + iSTFT → reconstrucție

SEA-CLUTTER EXPLANATION:
• Rezu pe mijloc (DC, f=0 Hz) = ecouuri statice de la suprafața mării
• Goluri/încrucișări (Gaps/Crosses) = ecouuri din calea obiectelor, speciale
• Adaptiv lateral = sprijin termic (lateral, stâlp)
• "Distrat" = energie este concentrată în anumite zone-time-frecvență (ridges)
• Tramele noastre ar apărea ca benzi clare de departe de DC ($\pm 100\text{-}400$ Hz)

GOCA-CFAR 2D – Detecție Adaptivă



GOCA = Greatest-Of Cell Averaging

$$\hat{Z} = \max(\mu_1, \mu_2, \mu_3, \mu_4)$$

$$T = R \cdot \hat{Z}$$

$$R = N_T(P_f^{-1/N_T} - 1)$$

Decizie:

Notă: excludem o „cruce” (buffer) între cadrane pentru a evita ridge/sidelobe-uri pe axe.

Parametri IPIX: $N_G = 3$, $N_T = 12$, $P_f = 0.001$
(semnificativ mai mic decat in paper!)

$$|X(k, n)|^2 \geq T \Rightarrow \text{Detectat}$$

Adaptări pentru Date Reale

1. K-Distribution:

- Sea clutter \neq Gaussian
- (heavy tails): datele marine au „margini” cu ponderi mari (valori extreme mai frecvente)
- Ajustare prag CFAR

2. Hurst Boost:

- Clutter: $H \approx 0.75\text{--}0.85$
- Target perturbă: $H < 0.6$
- Detectează target-uri slabe

3. DBSCAN Asimetric:

- Target-uri = linii verticale în TF
- Scalare frecvență: $s_f = 3.0$
- Un cluster per target

4. Mascare DC:

- ± 8 binuri în jurul 0 Hz
- Elimină returnări staționare

Rezultate pe Date Sintetice

SNR [dB]	RQF [dB]	Detectie
5	7.28	100%
10	16.81	100%
20	26.40	100%
30	29.17	100%

100 rulări Monte Carlo per SNR

RQF = Reconstruction Quality Factor

$$RQF = 10 \log_{10} \frac{\|x\|^2}{\|x - \hat{x}\|^2}$$

- ✓ Detectie 100%
- ✓ RQF creste cu SNR

Detectie pe Date IPIX Reale

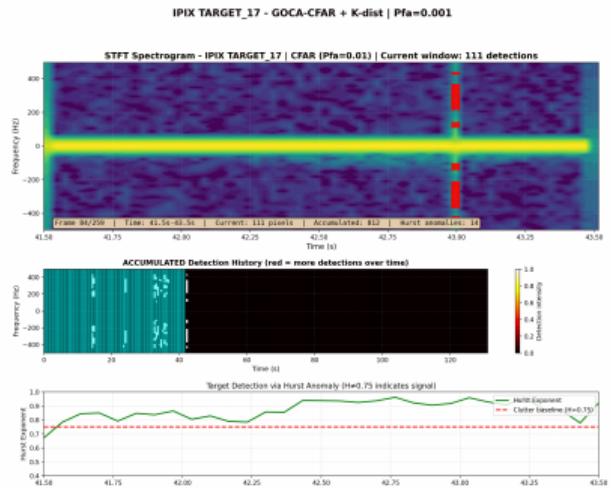


Figura: GOCA-CFAR pe Target #17

IPIX: Radar X-band 9.39 GHz, PRF=1000 Hz, target sferă 1m la 2660m

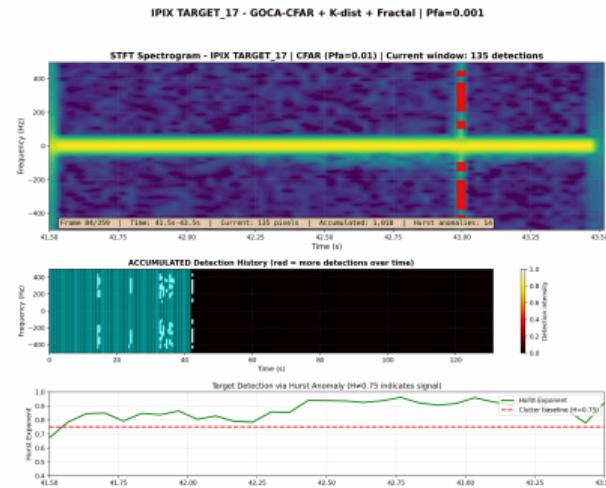


Figura: Cu Fractal Boost

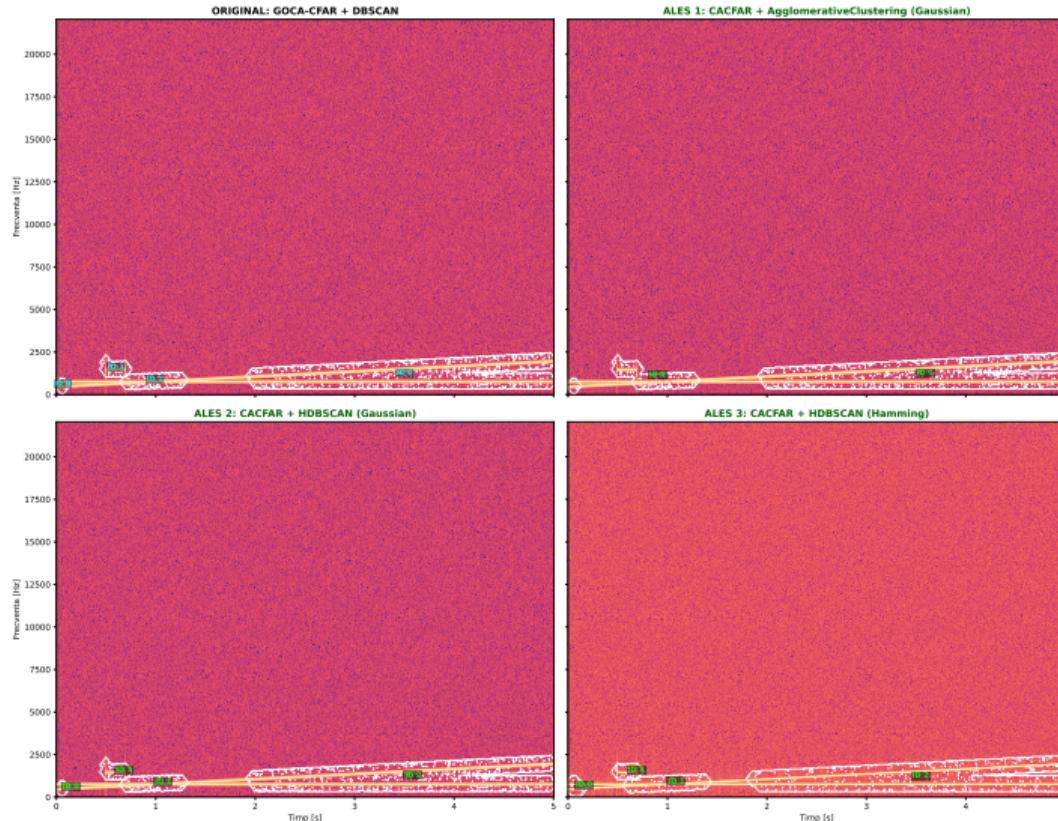
Comparație Metode CFAR

Metodă	Robustețe clutter	Target-uri slabe	Ideal pentru
CA-CFAR	Scăzută	Ridicată	Zgomot omogen
OS-CFAR	Foarte bună	Medie	Multi-target
SOCA-CFAR	Bună	Medie	Margini clutter
GOCA-CFAR	Foarte bună	Bună	Sea clutter

Observație experimentală: CA-CFAR eșuează la separare pe IPIX – detectiile sunt dominate de clutter, iar target-ul nu este izolat.

GOCA-CFAR + DBSCAN = performanță optimă pentru sea clutter neomogen

Comparație Spectrograme Metode



Rezultate Comparative pe IPIX

Metodă	Sea State	Componente	Viteză [m/s]
CA-CFAR + HDBSCAN	HIGH	1.0 ± 0.0	-0.05
CA-CFAR + HDBSCAN	LOW	1.0 ± 0.0	-0.01
Triangulare Delaunay	HIGH	4.2	+1.30
Triangulare Delaunay	LOW	13.6	-0.30

Probleme identificate:

- CA-CFAR: variabilitate zero \Rightarrow grupează tot clutter-ul într-un cluster
- Triangulare Delaunay: fragmentează clutter-ul în multe componente, reducând consistența detectiilor

Concluzii

- ① **Implementare completă CFAR-STFT în Python**
- ② **Validare sintetică:** RQF = 29.17 dB @ SNR=30dB, detectie 100%
- ③ **Validare IPIX:** Detectii consistente pe date reale
- ④ **Adaptări:** K-distribution, Hurst boost, DBSCAN asimetric
- ⑤ **Comparatie:** GOCA-CFAR superior CA-CFAR și triangulării

Cod: https://github.com/dirgnic/Radar_Detection_STFT

Mulțumim! Întrebări?